

EduTech Vision: Monitoramento de Atenção, Postura e Engajamento por Processamento Digital de Imagens

Fernando Cobianchi, Samuel Bernini

¹Bacharelado em Ciência da Computação
Universidade do Estado de Mato Grosso (UNEMAT)
Câmpus Universitário de Rondonópolis – Rondonópolis – MT – Brasil

`fernando.cobianchi@unemat.br, samuel.bernini@unemat.br`

Abstract. *EduTech Vision is a real-time digital image processing (DIP) system for demonstrating attention, posture and audience engagement in individual and audience modes, without student identification. The pipeline uses the OpenCV YuNet face detector, MediaPipe Face Landmarker, Eye/Mouth Aspect Ratios (EAR/MAR), Perspective-n-Point (PnP) pose, moving averages and 10 s aggregation. In 960x540 benchmarks, the enhanced configuration reached $F1=0.712$ in individual mode and $F1=0.583$ in audience mode; in a 1080p high-quality (HQ) audience audit, 10/11 counts were within one face. The system is a DIP demonstration, not a pedagogical or clinical diagnostic tool.*

Resumo. *O EduTech Vision é um sistema de Processamento Digital de Imagens (PDI) em tempo real para demonstrar atenção visual, postura e engajamento em modos individual e plateia, sem identificar estudantes. O pipeline usa o detector facial YuNet da OpenCV, MediaPipe Face Landmarker, razões olho/boca (EAR/MAR), pose Perspective-n-Point (PnP), médias móveis e agregação de 10 s. Em benchmarks 960x540, a configuração enhanced alcançou $F1=0,712$ no modo individual e $F1=0,583$ no modo plateia; em auditoria 1080p de alta qualidade (HQ), 10/11 contagens ficaram a até um rosto do valor manual. O sistema é demonstração de PDI, não avaliação pedagógica ou diagnóstico clínico.*

1. Introdução

A observação de atenção, postura e engajamento em ambientes educacionais costuma depender da percepção do professor ou do próprio estudante. Essa percepção é útil, mas é subjetiva, descontínua e difícil de registrar de forma reproduzível. Em projetos de Processamento Digital de Imagens (PDI), sinais visuais como abertura dos olhos, abertura da boca, orientação da cabeça e presença de faces podem ser utilizados para demonstrar como medidas geométricas e temporais transformam imagens em indicadores aproximados.

Neste contexto, o EduTech Vision foi desenvolvido como produto acadêmico da Trilha 3: Atenção, Postura e Engajamento. O sistema possui dois cenários complementares: no modo individual, uma câmera frontal acompanha uma pessoa e estima fadiga, bocejo, queda postural e desatenção sustentada; no modo plateia, uma câmera voltada a um grupo calcula métricas agregadas de faces voltadas ao palco ou professor. O modo plateia não identifica alunos e não produz decisões individualizadas.

O objetivo deste artigo é apresentar a versão entregue do sistema com linguagem científica e evidências compatíveis com os resultados disponíveis. O trabalho não afirma medir aprendizagem, rendimento escolar ou estado clínico. Os indicadores gerados são aproximações visuais para fins de demonstração acadêmica de PDI em tempo real.

2. Fundamentação

PDI e visão computacional combinam aquisição, pré-processamento, extração de características e tomada de decisão para interpretar padrões visuais [Gonzalez and Woods 2018, Szeliski 2022]. Em aplicações com faces, detectores localizam regiões de interesse e são avaliados em bases como WIDER FACE [Yang et al. 2016], enquanto modelos de landmarks estimam pontos anatômicos que permitem calcular medidas geométricas. O uso de detectores pré-treinados como front-end é adequado quando o processamento posterior explicita o núcleo de PDI, como ocorre com razões geométricas, estimativa de pose e suavização temporal.


No modo individual, a razão de aspecto dos olhos, ou Eye Aspect Ratio (EAR), é calculada pela razão entre distâncias verticais e horizontais de pontos das pálpebras, abordagem comum em detecção de piscadas por landmarks faciais [Soukupová and Čech 2016]. Reduções sustentadas do EAR indicam olhos fechados por mais tempo que uma piscada comum. De modo análogo, a Mouth Aspect Ratio (MAR) relaciona abertura vertical e largura da boca, permitindo sinalizar bocejo quando o valor permanece elevado. Essas métricas são sensíveis a escala, pose, iluminação e qualidade dos landmarks; por isso são suavizadas antes da decisão.

A postura e o foco visual aproximado são estimados por pose de cabeça. O sistema usa correspondências bidimensionais-tridimensionais (2D-3D) de pontos faciais e a função solvePnP, baseada no problema Perspective-n-Point, para obter yaw, pitch e roll [Lepetit et al. 2009]. No modo plateia, yaw e pitch são comparados a um eixo de referência calibrado no início da sessão. A decisão final é agregada em janela temporal, pois quadros isolados podem conter ruído, oclusões ou landmarks incompletos.

3. Sistema Proposto

A Figura 1 sintetiza o pipeline entregue. A entrada pode ser câmera ou vídeo, processada em resolução padrão de 960x540. O perfil padrão é enhanced, isto é, uma configuração reforçada em que o YuNet da OpenCV detecta faces, aplica supressão de não máximos e prioriza candidatos [Wu et al. 2023]; em seguida, cada região é recortada com margem ampliada e enviada ao MediaPipe Face Landmarker [Google 2026]. O perfil mediapipe é mantido como baseline, ou linha de base comparativa, enquanto o perfil research, baseado no detector Sample and Computation Redistribution for Efficient Face Detection (SCRFD) [Guo et al. 2022], é apenas comparativo acadêmico e não constitui o padrão de distribuição.

No modo individual, a configuração entregue usa confiança facial 0,70 e no máximo uma face. A primeira etapa de uso realiza calibração de 5 s para estabelecer referências de EAR, MAR, yaw e pitch. Em seguida, as medidas passam por média móvel de janela 7 e por condições sustentadas, evitando que piscadas ou movimentos pontuais acionem alertas. Os alertas visuais indicam fadiga, bocejo, postura ruim e desatenção, sem atribuir diagnóstico clínico.



Saídas: dashboard OpenCV, logs CSV, graficos e relatorio HTML/PDF, sem identificacao individual no modo plateia.

Figura 1. Pipeline do EduTech Vision. NMS indica supressão de não máximos.

No modo plateia, a configuração entregue usa confiança facial 0,60, limite de 24 faces, tolerância de 30 graus em yaw, tolerância de 20 graus em pitch e janela de agregação de 10 s. Faces detectadas sem landmarks confiáveis podem aparecer no painel visual como detecções anônimas, mas não entram no cálculo de pose e engajamento. A saída persistida é agregada, composta por séries temporais e estatísticas da sessão.

4. Metodologia Experimental

A avaliação foi organizada em quatro frentes. A primeira é um benchmark preliminar automatizado do detector, que compara a linha de base MediaPipe em quadro inteiro com o perfil enhanced nos dois modos. As métricas são recall de face, recall de landmarks, precisão, F1, FPS médio e FPS mínimo. O recall de face considera uma caixa localizada corretamente; o recall de landmarks é mais restritivo e exige que a face também gere pontos suficientes para EAR, MAR ou pose.

A segunda frente é a auditoria de alta qualidade (HQ) de plateia. Nessa avaliação, vídeos 1080p são processados integralmente e quadros selecionados são comparados com contagens manuais de rostos avaliáveis. As métricas são acertos exatos, casos com erro de no máximo um rosto, erro absoluto médio, presença da contagem manual dentro da janela temporal de mais ou menos 1 s, quadros por segundo (FPS) médio e FPS no percentil 10.

A terceira frente é o relatório de sessão. Ele demonstra instrumentação da aplicação por meio de logs em valores separados por vírgula (CSV), gráficos, relatório em HyperText Markup Language (HTML), relatório em Portable Document Format (PDF), timeline de eventos e telemetria. Esses artefatos são usados para evidenciar capacidade de registro e reprodutibilidade da demonstração, e não como verdade final dos protocolos formais.

Por fim, a versão entregue contém metodologia e scripts para os cinco protocolos formais do plano da disciplina: robustez luminosa, resiliência a oclusão, telemetria de FPS, matriz de confusão e tolerância a falhas. Entretanto, não foram usados resultados históricos, preliminares ou logs finais antigos como evidência da entrega. Na ausência de novos registros experimentais finais desses cinco protocolos, eles são tratados neste artigo como metodologia disponível para reexecução. O suporte a reconexão de câmera é descrito apenas como característica de robustez implementada, não como resultado experimental principal.

5. Resultados

A Tabela 1 apresenta o benchmark preliminar automatizado da versão entregue. Em ambos os modos, o perfil enhanced aumenta substancialmente o recall de face e o F1 em relação à linha de base MediaPipe, mantendo desempenho em tempo real. A redução de FPS é esperada, pois o pipeline passa a executar detecção por YuNet, recortes ampliados e landmarks em regiões de interesse, em vez de depender apenas do rastreamento direto no quadro inteiro.

Tabela 1. Benchmark preliminar automatizado do detector em 960x540.

Modo	Perfil	Recall face	Recall landmarks	Precisão	F1	FPS médio	FPS mín.
Individual	mediapipe	0,193	0,193	1,000	0,324	242,4	91,7
Individual	enhanced	0,592	0,294	0,894	0,712	29,0	19,3
Plateia	mediapipe	0,011	0,011	1,000	0,022	491,6	154,6
Plateia	enhanced	0,443	0,089	0,851	0,583	74,5	56,3

A Tabela 2 resume a auditoria HQ do modo plateia com a configuração enhanced, confiança 0,60 e limite de 24 faces. Diferentemente da Tabela 1, essa avaliação usa vídeos 1080p completos, cenas mais pesadas e comparação com contagem manual em quadros específicos. Portanto, o FPS dessa auditoria não deve ser comparado diretamente com o FPS do benchmark de detector em 960x540.

Tabela 2. Auditoria HQ de plateia com configuração enhanced, confiança 0,60 e limite de 24 faces.

Métrica	Resultado
Acertos exatos	5/11
Erro de no máximo 1 rosto	10/11
Erro absoluto médio	0,636 rosto
Manual dentro da janela +/- 1 s	10/11
FPS médio	13,3
FPS p10	9,4

A matriz de confusão disponível na entrega é demonstrativa. Ela contém 50 amostras sintéticas de atenção e desatenção, usadas para testar o fluxo de cálculo, visualização e relatório. A Tabela 3 mostra que houve 46 acertos e 4 erros, produzindo acurácia, precisão macro, recall macro e F1 macro de 0,92. Como as amostras são explicitamente demonstrativas, esse resultado não é apresentado como validação científica real; a validação final exige amostras reais rotuladas.

Tabela 3. Matriz de confusão demonstrativa com 50 amostras.

Classe real	Predito atento	Predito desatento
Atento	23	2
Desatento	2	23

O relatório de sessão demonstra que a aplicação gera CSVs de telemetria, gráficos, páginas HTML, PDF e linha do tempo de eventos. Seus valores numéricos não foram usados para substituir a reexecução formal dos cinco protocolos, mas comprovam que o sistema está instrumentado para registrar sessões e produzir artefatos analisáveis.

6. Discussão

Os resultados justificam o uso do perfil enhanced como padrão. O baseline MediaPipe é muito rápido, mas perde muitas faces pequenas ou distantes, sobretudo no modo plateia. O uso de YuNet antes dos landmarks aumenta o recall de faces e torna a interface mais útil para demonstrações com mais de uma pessoa. A principal contrapartida é a queda de FPS e a diferença entre detecção de face e disponibilidade de landmarks.

Essa diferença é importante para interpretar o sistema. Uma face pode ser localizada por caixa, mas não gerar landmarks estáveis o suficiente para pose, EAR ou MAR. Nesses casos, a face pode ser desenhada de forma anônima, mas não deve influenciar métricas de atenção ou engajamento. Por isso, recall de face e recall de landmarks são relatados separadamente.

Também há diferença metodológica entre o FPS do benchmark e o FPS da auditoria HQ. O benchmark preliminar mede o pipeline do detector em 960x540, com foco em comparação controlada entre perfis. A auditoria HQ processa vídeos 1080p completos, registra respostas por frame e avalia cenas com maior densidade visual. É esperado que os valores absolutos de FPS sejam menores nesse contexto.

7. Considerações Éticas e Lei Geral de Proteção de Dados

O EduTech Vision trata imagem de pessoas e, portanto, deve ser usado com minimização de dados, transparência e finalidade acadêmica. No modo individual, a captura deve ocorrer com consentimento do participante e sem uso punitivo, clínico ou classificatório. No modo plateia, o sistema opera apenas com métricas agregadas e não deve identificar alunos, registrar nomes, persistir frames ou permitir reidentificação.

Por padrão, a proposta privilegia processamento local, descarte de imagens e armazenamento apenas de séries temporais, contagens, percentuais agregados e eventos de interface. Relatórios e gráficos devem ser usados para explicar o comportamento do pipeline, não para vigiar indivíduos. Em demonstrações públicas, recomenda-se sinalização visível sobre a captura de imagem, opção de afastamento da câmera e uso de voluntários quando forem necessárias evidências visuais.

Essas escolhas atendem ao princípio de necessidade da Lei Geral de Proteção de Dados (LGPD) [Brasil 2018] e reduzem o risco de interpretação abusiva. O sistema deve ser entendido como material didático de PDI, não como tecnologia de decisão automatizada sobre estudantes.

8. Limitações

As limitações observadas são coerentes com aplicações de visão computacional em tempo real. Iluminação irregular, distância da câmera, oclusão parcial, rostos em perfil, faces pequenas, motion blur e cortes nas bordas reduzem a estabilidade dos landmarks. No modo individual, EAR e MAR variam entre pessoas e dependem da calibração inicial. No modo plateia, a métrica agregada estima orientação visual aproximada e não atenção cognitiva ou aprendizagem. Além disso, os cinco protocolos formais devem ser reexecutados com novos registros experimentais para substituir a matriz demonstrativa e completar a validação quantitativa final.

9. Conclusão

Este artigo apresentou a versão entregue do EduTech Vision, uma aplicação funcional de PDI em tempo real para monitoramento aproximado de atenção visual, postura e engajamento agregado. A arquitetura combina YuNet, MediaPipe Face Landmarker em recortes ampliados, EAR, MAR, solvePnP, suavização temporal e relatórios de sessão. O benchmark preliminar mostra que o perfil enhanced supera a linha de base MediaPipe em recall e F1 nos dois modos, enquanto a auditoria HQ indica desempenho aceitável para contagem agregada em vídeos mais pesados.

As evidências disponíveis sustentam o sistema como demonstração reproduzível e tecnicamente coerente para a Trilha 3. Ao mesmo tempo, a matriz de confusão disponível é apenas demonstrativa e os cinco protocolos formais devem ser reexecutados com novos registros experimentais finais para uma validação máxima da entrega. Trabalhos futuros incluem ampliar amostras reais rotuladas, testar diferentes condições de iluminação e distância, melhorar a estabilidade de landmarks em rostos pequenos e refinar a comunicação ética do uso em ambientes educacionais.

Agradecimentos

Os autores agradecem ao curso de Bacharelado em Ciência da Computação da UNEMAT e ao docente da disciplina de Processamento Digital de Imagens pelas diretrizes do projeto. Ferramentas de inteligência artificial (IA) generativa foram utilizadas pontualmente como apoio à revisão gramatical e à organização textual; o conteúdo técnico, a interpretação dos resultados e a responsabilidade final permanecem dos autores.

Referências

- Brasil (2018). Lei n. 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais.
- Gonzalez, R. C. and Woods, R. E. (2018). *Digital Image Processing*. Pearson, 4 edition.
- Google (2026). MediaPipe Face Landmarker. Disponível em: <https://developers.google.com/mediapipe>. Acesso em: 2026.
- Guo, J., Deng, J., Lattas, A., and Zafeiriou, S. (2022). Sample and Computation Redistribution for Efficient Face Detection. In *International Conference on Learning Representations*.
- Lepetit, V., Moreno-Noguer, F., and Fua, P. (2009). EPnP: An accurate O(n) solution to the PnP problem. *International Journal of Computer Vision*, 81:155–166.
- Soukupová, T. and Čech, J. (2016). Real-Time Eye Blink Detection using Facial Landmarks. In *Proceedings of the 21st Computer Vision Winter Workshop*.
- Szeliski, R. (2022). *Computer Vision: Algorithms and Applications*. Springer, 2 edition.
- Wu, W., Peng, H., and Yu, S. (2023). YuNet: A tiny millisecond-level face detector. *Machine Intelligence Research*, 20(5):656–665. DOI: 10.1007/s11633-023-1423-y.
- Yang, S., Luo, P., Loy, C. C., and Tang, X. (2016). WIDER FACE: A face detection benchmark. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*.