

EduTech Vision: Atenção, Postura e Engajamento por Visão Computacional em Tempo Real

Fernando Cobianchi, Samuel Bernini

Bacharelado em Ciência da Computação -- Universidade do Estado de Mato Grosso
(UNEMAT)

Campus Universitário de Rondonópolis -- Rondonópolis -- MT -- Brasil

{fernando.cobianchi, samuel.bernini}@unemat.br

Abstract. *EduTech Vision is a real-time digital image processing system for educational demonstrations of visual attention, posture and audience engagement. The standard pipeline combines OpenCV YuNet face detection, expanded face crops, MediaPipe Face Landmarker, EAR/MAR geometric metrics, solvePnP head pose, moving averages and temporal state machines. In a reproducible smoke benchmark at 960x540, the enhanced profile improved face recall from 0.193 to 0.592 in individual mode and from 0.011 to 0.443 in audience mode, with F1 of 0.712 and 0.583. A specific individual-mode audit processed 15,193 full-video frames and obtained 86.6% valid face/metric frames and 82.5% frontal frames. The system is a computer vision demonstration, not a clinical or pedagogical diagnostic tool.*

Resumo. *Este artigo apresenta o EduTech Vision, um sistema de processamento digital de imagens em tempo real para demonstrações educacionais de atenção visual, postura e engajamento de plateia. O pipeline padrão combina detecção facial OpenCV YuNet, recortes faciais ampliados, MediaPipe Face Landmarker, métricas geométricas EAR/MAR, pose de cabeça por solvePnP, médias móveis e máquinas de estados temporais. Em benchmark smoke reproduzível a 960x540, o perfil enhanced elevou o recall de face de 0,193 para 0,592 no modo individual e de 0,011 para 0,443 no modo plateia, com F1 de 0,712 e 0,583. Uma auditoria específica do modo individual processou 15.193 frames de vídeos completos e obteve 86,6% de frames com face/métricas válidas e 82,5% de frames frontais. O sistema é uma demonstração de visão computacional, não uma ferramenta diagnóstica clínica ou pedagógica.*

Introdução

A observação de atenção, postura e engajamento em contextos educacionais costuma depender da percepção subjetiva do professor ou do próprio estudante. Essa percepção pode ser pedagogicamente útil, mas é descontínua, difícil de registrar e pouco reproduzível. Em Processamento Digital de Imagens (PDI), sinais visuais como abertura dos olhos, abertura da boca, orientação da cabeça e quantidade de faces no quadro permitem demonstrar como imagens podem ser transformadas em indicadores geométricos e temporais.

O EduTech Vision foi desenvolvido na Trilha 3 da disciplina de PDI com dois cenários complementares. No modo individual, uma câmera frontal acompanha uma

pessoa e estima fadiga ocular, bocejo, queda postural e desatenção sustentada. No modo plateia, uma câmera voltada a um grupo estima, de forma agregada, a proporção de faces com pose orientada ao palco ou professor. O sistema não realiza reconhecimento de identidade e não mede aprendizagem.

O objetivo deste artigo é apresentar a versão final do produto, sua fundamentação técnica, o pipeline de processamento, a metodologia experimental e os resultados quantitativos disponíveis. A escrita prioriza evidências numéricas e limitações, pois os indicadores gerados são aproximações visuais para demonstração acadêmica de PDI em tempo real.

Fundamentação Teórica

PDI e visão computacional organizam etapas de aquisição, pré-processamento, segmentação, extração de características e interpretação visual [Gonzalez and Woods 2018, Szeliski 2022]. Em aplicações com faces, detectores localizam regiões de interesse, enquanto modelos de landmarks estimam pontos faciais que permitem calcular métricas geométricas e pose.

No modo individual, o Eye Aspect Ratio (EAR) é calculado pela razão entre distâncias verticais e horizontais de landmarks dos olhos, seguindo a ideia de detecção de piscadas por geometria facial [Soukupova and Cech 2016]. Quando os olhos fecham, as distâncias verticais diminuem e o EAR cai. A Mouth Aspect Ratio (MAR) usa princípio semelhante para representar abertura da boca e sinalizar bocejos sustentados.

A orientação da cabeça é estimada por correspondências 2D-3D e pela família de algoritmos solvePnP [Lepetit et al. 2009]. A partir de landmarks como nariz, queixo, cantos dos olhos e boca, o sistema estima yaw, pitch e roll. Esses ângulos são suavizados no tempo porque frames isolados podem conter ruído de landmark, oclusão ou blur de movimento.

A detecção inicial de faces foi avaliada contra o uso direto de MediaPipe no quadro completo [Lugaresi et al. 2019]. O benchmark WIDER FACE [Yang et al. 2016] foi usado como base anotada para medir recall, precisão e F1 em diferentes tamanhos de face, distâncias e perturbações sintéticas.

Metodologia e Pipeline

A Figura 1 resume o pipeline operacional. A entrada é uma webcam ou arquivo de vídeo redimensionado para 960x540 no modo padrão. O perfil enhanced aplica OpenCV YuNet para localizar faces, usa supressão de não máximos e recortes ampliados, e então executa MediaPipe Face Landmarker em cada região de interesse. Essa escolha preserva o MediaPipe para landmarks e desloca o gargalo de faces pequenas para um detector frontal mais adequado.

Três perfis foram mantidos para comparação metodológica. O perfil mediapipe é o baseline, com processamento direto do quadro. O perfil enhanced é o padrão distribuível, combinando YuNet e landmarks em crops. O perfil research usa SCRFD/InsightFace apenas como comparativo acadêmico opcional; o padrão de entrega é o perfil enhanced.

No modo individual, o sistema usa no máximo uma face e confiança facial 0,70. A calibração dura 5 s a partir da primeira amostra facial válida, evitando baseline vazio quando a câmera ou vídeo inicia sem rosto. O baseline armazena medianas e desvios robustos de EAR, MAR, yaw e pitch. Para yaw/pitch, a estatística é circular: valores próximos de +179 e -179 graus são tratados como orientações equivalentes, não como extremos opostos.

Os alertas usam médias móveis e condições sustentadas. Fadiga ocular exige EAR médio abaixo do limiar dinâmico e queda simultânea dos dois olhos; bocejo exige MAR acima do limiar; postura usa desvio de pitch; e desatenção usa desvio de yaw. No modo plateia, cada face com pose válida é comparada a um eixo de palco calibrado, e os resultados são agregados em janelas de 10 s.



Saídas: painel OpenCV, logs CSV, gráficos, relatório HTML/PDF e métricas agregadas de plateia

Figura 1. Pipeline atual do EduTech Vision.

Metodologia Experimental

A avaliação foi organizada em quatro frentes. A primeira foi um benchmark smoke do detector, comparando o baseline mediapipe e o perfil enhanced nos modos individual e plateia. As métricas foram recall de face, recall de landmarks, precisão, F1, FPS médio e FPS mínimo. O recall de face mede caixas detectadas; o recall de landmarks exige também pontos suficientes para EAR, MAR ou pose.

A segunda frente foi uma auditoria específica do modo individual. Foram baixados vídeos frontais 1080p e retratos estáticos por manifesto reproduzível. O auditor processou vídeos completos, sem amostragem por intervalo, redimensionando cada frame para a mesma resolução operacional do app. Cada frame gerou uma linha com detecção, qualidade dos landmarks, EAR, MAR, yaw, pitch, deltas em relação ao baseline e classificação frontal/neutra.

A terceira frente foi a auditoria HQ de plateia. Vídeos 1080p completos foram processados do primeiro ao último frame e quadros selecionados foram comparados a contagens manuais de rostos avaliáveis. Foram medidos acertos exatos, erro de no máximo um rosto, erro absoluto médio, presença da contagem manual em janela temporal de +/-1 s, FPS médio e FPS p10.

A quarta frente foi a instrumentação dos protocolos formais: iluminação, oclusão, FPS, matriz de confusão e tolerância a falhas. Na versão atual, apenas a matriz demonstrativa possui resultado consolidado; os demais protocolos estão implementados como scripts de coleta, mas não foram usados como evidência final por falta de nova execução presencial completa. Essa limitação é explicitada para evitar uso indevido de logs preliminares.

Resultados

A Tabela 1 apresenta o benchmark smoke canônico da versão atual. Em ambos os modos, o perfil enhanced aumenta substancialmente o recall de face e o F1 em relação ao baseline MediaPipe, mantendo desempenho em tempo real. A redução de FPS é esperada porque o pipeline passa a executar detecção por YuNet, recortes ampliados e landmarks em regiões de interesse.

Tabela 1. Benchmark smoke do detector em resolução 960x540.

Modo	Perfil	Recall face	Recall landmarks	Precisão	F1	FPS médio
Individual	mediapipe	0,193	0,193	1,000	0,324	242,4
Individual	enhanced	0,592	0,294	0,894	0,712	27,6
Plateia	mediapipe	0,011	0,011	1,000	0,022	491,6
Plateia	enhanced	0,443	0,089	0,851	0,583	74,5

A Tabela 2 mostra a auditoria específica do modo individual. Nos três vídeos frontais completos, o sistema processou 15.193 frames. Os frames sem face dos vídeos NASA correspondem principalmente a cartelas e b-roll de abertura, não a perda sistemática de rosto frontal. Quando havia pessoa frontal no quadro, os deltas medianos foram pequenos: 4,0 graus em yaw e 1,8 grau em pitch.

Tabela 2. Auditoria do modo individual em vídeos frontais completos.

Métrica	Valor
Vídeos processados	3
Frames totais	15.193
Frames com face/métricas válidas	86,6%
Frames frontais	82,5%
Frames neutros em pose	76,7%
Frames aprovados	73,0%
Yaw delta mediano	4,0 graus
Pitch delta mediano	1,8 grau

A Tabela 3 resume a auditoria HQ de plateia com a configuração enhanced, confiança 0,60 e limite de 24 faces. Essa avaliação é mais pesada que o benchmark smoke porque usa vídeos 1080p completos e compara a saída temporal do app com contagens manuais.

Tabela 3. Auditoria HQ de plateia com enhanced, confiança 0,60 e 24 faces.

Configuração	Exatos	Erro <=1	Erro médio	Manual em +/-1s	FPS médio	FPS p10
enhanced c0,60 m24	5/11	10/11	0,636	10/11	13,3	9,4

A matriz de confusão disponível contém 50 amostras sintéticas de atenção/desatenção, usadas para testar o fluxo de cálculo, visualização e relatório. O resultado foi acurácia, precisão macro, recall macro e F1 macro de 0,92. Por serem amostras demonstrativas, esses valores não substituem uma validação científica com rotulação real.

Discussão

Os resultados justificam o perfil enhanced como padrão. O baseline mediapipe é muito rápido, mas perde faces pequenas ou distantes, sobretudo no modo plateia. A combinação YuNet + crops + landmarks aumenta a utilidade visual do produto sem exigir treinamento próprio. Separar recall de face e recall de landmarks evita uma interpretação incorreta: uma caixa pode estar correta, mas ainda não oferecer pontos confiáveis para pose ou EAR/MAR.

No modo individual, os principais ajustes metodológicos foram motivados pelos testes. O pitch retornado por solvePnP pode alternar entre +179 e -179 graus para faces frontais; por isso o baseline passou a usar média circular. A calibração também passou a esperar a primeira face válida, pois vídeos com abertura sem rosto geravam baseline inadequado. Esses dois pontos aumentaram a consistência dos deltas de pose em vídeos frontais.

Ainda há limitações importantes. Iluminação irregular, contraluz, oclusões, rosto em perfil, distância excessiva, motion blur e cortes nas bordas reduzem a estabilidade de landmarks. No modo plateia, a estimativa é agregada e visual; ela não mede atenção cognitiva. No modo individual, EAR e MAR variam entre pessoas e dependem de calibração inicial.

Considerações Éticas e LGPD

Como o sistema captura imagem de pessoas, seu uso deve seguir minimização de dados, transparência e finalidade acadêmica. O modo individual deve ser demonstrado com consentimento do participante e sem finalidade punitiva, clínica ou classificatória. O modo plateia deve operar com métricas agregadas e não deve identificar alunos, associar nomes a rostos ou produzir avaliação individual de aprendizagem.

A proposta privilegia processamento local e armazenamento apenas de telemetria numérica, como séries temporais, contagens, percentuais agregados e eventos de interface. Em demonstrações públicas, recomenda-se sinalização visível, opção de ficar fora do campo da câmera e uso de voluntários quando forem necessárias evidências visuais.

Conclusão

Este artigo apresentou o EduTech Vision como aplicação de PDI em tempo real para monitoramento aproximado de atenção visual, postura e engajamento agregado. A arquitetura final combina YuNet, MediaPipe Face Landmarker em recortes ampliados, EAR, MAR, solvePnP, suavização temporal, painel OpenCV e relatórios de sessão.

As evidências quantitativas mostram ganho claro do perfil enhanced sobre o baseline mediapipe e uma auditoria específica mais forte para o modo individual. Ao mesmo tempo, o artigo delimita o escopo: o sistema é uma demonstração acadêmica e não uma ferramenta diagnóstica ou avaliativa. Trabalhos futuros incluem reexecutar os cinco protocolos formais com coleta presencial completa, ampliar amostras reais rotuladas e testar condições controladas de iluminação, distância e oclusão.

Agradecimentos

Os autores agradecem ao curso de Bacharelado em Ciência da Computação da UNEMAT e ao docente da disciplina de Processamento Digital de Imagens pelas diretrizes, críticas e critérios de avaliação do projeto. Ferramentas de IA generativa foram utilizadas pontualmente como apoio à revisão gramatical e à organização textual; o conteúdo técnico, a interpretação dos resultados e a responsabilidade final permanecem dos autores.

Referências

- Brasil (2018). Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD).
- Gonzalez, R. C. and Woods, R. E. (2018). Digital Image Processing. 4. ed. Pearson.
- Lepetit, V., Moreno-Noguer, F. and Fua, P. (2009). EPnP: An Accurate $O(n)$ Solution to the PnP Problem. International Journal of Computer Vision, 81(2):155-166.
- Lugaresi, C. et al. (2019). MediaPipe: A Framework for Building Perception Pipelines. arXiv:1906.08172.
- OpenCV Zoo (2026). YuNet Face Detection Model. Disponível em: https://github.com/opencv/opencv_zoo.
- Soukupova, T. and Cech, J. (2016). Real-Time Eye Blink Detection using Facial Landmarks. 21st Computer Vision Winter Workshop.
- Szeliski, R. (2022). Computer Vision: Algorithms and Applications. 2. ed. Springer.
- Yang, S., Luo, P., Loy, C. C. and Tang, X. (2016). WIDER FACE: A Face Detection Benchmark. Proceedings of CVPR.